

### § 3.4 滑动平均模型的拟合

设  $x_1, \dots, x_n$  为来自  $MA(q)$  模型的样本值:

$$x_t = \varepsilon_t - \beta_1 \varepsilon_{t-1} - \beta_2 \varepsilon_{t-2} - \dots - \beta_q \varepsilon_{t-q}, \quad t = 1, 2, \dots, n \quad (3.4.1)$$

其中  $\{\varepsilon_t\}$  为独立序列, 且  $E\varepsilon_t = 0$ ,  $E\varepsilon_t^2 = \sigma^2$ ,  $E\varepsilon_t^4 < +\infty$ 。

#### 一、阶数 $q$ 的估计

若  $MA(q)$  模型中阶数  $q$  未知, 首先要对其进行估计, 估计的方法有自相关函数估计法、AIC 准则估计法等等。

##### 1. 自相关函数分析法

因为一个平稳序列为  $MA(q)$  模型的充要条件是, 其自协方差函数  $\rho_k$  在  $q$  以后截尾, 所以可以借助这一特征作为估计阶数  $q$  的依据。在实际中, 是利用所知样本值, 先对自协方差函数的进行估计, 再对阶数  $q$  进行估计, 估计的步骤为:

(1) 首先由  $x_1, x_2, \dots, x_n$  计算均值  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ;

(2) 计算样本自协方差函数

$$\hat{\gamma}_k = \frac{1}{n} \sum_{j=1}^{n-k} (x_j - \bar{x})(x_{k+j} - \bar{x}) \quad k = 0, 1, 2, \dots$$

(3) 计算样本自相关函数

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}$$

(4) 将  $(k, \hat{\rho}_k)$  描在笛卡尔坐标图上, 若从某个  $k$  以后,  $\hat{\rho}_k$  明显接近于零, 则该  $k$  即

为所求阶数  $q$  的估计  $\hat{q}$ 。

##### 2. AIC (BIC) 准则法

类似于  $AR(p)$  模型中  $p$  的确定方法, 确定  $MA(q)$  模型中  $q$  的阶数步骤为:

(1) 凭经验确定  $q$  的上限  $Q$ ,  $0 \leq q \leq Q$

(2) 再由  $x_1, x_2, \dots, x_n$  求  $\sigma^2(j)$  的估计  $\hat{\sigma}^2(j)$

$$\hat{\sigma}^2(j) = \hat{\gamma}_0 (1 + \sum_{i=1}^j \hat{\beta}_i^2) \quad j = 1, 2, \dots, Q$$

$$(3) \quad \text{令 } A(j) = \text{AIC}(j) = \ln \hat{\sigma}^2(j) = \frac{2j}{n}$$

$$\text{或 } \text{BIC}(j) = \ln \hat{\sigma}^2(j) + \frac{j \log n}{n}$$

从  $A(1), A(2), \dots, A(j), \dots, A(Q)$  中选取最小值  $\hat{q}$ , 即  $\hat{q}$  满足

$$\text{AIC}(\hat{q}) = \min_{1 \leq j \leq Q} \text{AIC}(j)$$

由此得出的  $\hat{q}$  即为  $q$  的 AIC 准则估计。

## 二、 $MA(q)$ 模型参数的估计方法

### 1. 矩估计法

设对原始数据作中心化处理后所得的中心化样本值数据为  $x_1, \dots, x_n$ , 计算其自相关函数

数  $\gamma_k$  的估计值  $\hat{\gamma}_k$ , 再代入滑动平均模型  $MA(q)$  的参数与自相关函数的关系式中, 即得

$$\begin{cases} \hat{\sigma}^2 (1 + \sum_{j=1}^q \beta_j^2) = \hat{\gamma}_0 \\ \hat{\sigma}^2 (-\hat{\beta}_k + \sum_{j=1}^{q-k} \hat{\beta}_j \hat{\beta}_{j+k}) = \hat{\gamma}_k \end{cases} \quad (3.4.2)$$

$$\begin{cases} \hat{\sigma}^2 (-\hat{\beta}_k + \sum_{j=1}^{q-k} \hat{\beta}_j \hat{\beta}_{j+k}) = \hat{\gamma}_k \end{cases} \quad k = 1, 2, \dots, q \quad (3.4.3)$$

从中解出  $\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_q)$  与  $\hat{\sigma}^2$ , 这样的  $\hat{\beta}$  与  $\hat{\sigma}^2$  即为  $\beta, \sigma^2$  的矩估计。

例如对于  $q=1$  时的  $MA(1)$  模型, 由样本值  $x_1, \dots, x_n$  计算出  $\hat{\gamma}_0$  与  $\hat{\gamma}_1$ , 代入关系式中即得

$$\begin{cases} \hat{\sigma}^2 (1 + \beta_1^2) = \hat{\gamma}_0 \\ \hat{\sigma}^2 (-\hat{\beta}_1) = \hat{\gamma}_1 \end{cases}, \quad \text{从而有} \quad \begin{aligned} \hat{\sigma}^2 &= -\frac{\hat{\gamma}_1}{\beta_1} \\ \hat{\beta}_1 &= \left( \frac{\hat{\gamma}_0}{\hat{\sigma}^2} - 1 \right)^{\frac{1}{2}} \end{aligned}$$

为所求  $MA(1)$  的参数矩估计。

### 2. 极大似然估计法

若  $\{\varepsilon_t\}$  为独立且同分布序列,  $\varepsilon_t \sim N(0, \sigma^2)$   $t = 1, 2, \dots$ , 而

$$x_t = \varepsilon_t - \sum_{k=1}^q \beta_k \varepsilon_{t-k}$$

由概率论知识可知,  $x_1, \dots, x_n$  亦服从正态分布。即

$x = (x_1, \dots, x_n) \sim N(0, \Gamma_n)$ , 其概率密度函数, 即似然函数为:

$$L(\beta, \sigma^2) = f(x_1, x_2, \dots, x_n; \beta, \sigma^2) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Gamma_n|^{\frac{1}{2}}} \exp(-x' \Gamma_n^{-1} x) \quad \text{其中 } \Gamma_n \text{ 为}$$

$x_1, \dots, x_n$  的协方差阵, 对上式两端取对数, 即得

$$\ln L(\beta, \sigma^2) = \frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln(\Gamma_n) - \frac{1}{2} x' \Gamma_n^{-1} x$$

再求  $\hat{\beta}, \hat{\sigma}^2$  使  $\ln L(\hat{\beta}, \hat{\sigma}^2) = \max\{\ln L(\beta, \sigma^2)\}$ , 由此方法求出的则此  $\hat{\beta}, \hat{\sigma}^2$  即为  $\beta$  与  $\sigma^2$  极大似然估计。

但实际上求解上述似然函数的极大值, 即求  $\beta$  与  $\sigma^2$  的严格的极大似然估计非常困难, 所以在实际应用中经常采用近似的极大似然估计法

### 3. 近似极大似然估计法

设由 (4.1) 式中  $\{\varepsilon_t\}$  的初值  $\varepsilon_0, \varepsilon_1, \varepsilon_2, \dots, \varepsilon_{-q+1}$  被给定, 不妨假设它们近似为 0,

这样, 由 (4.1) 式和样本值  $x_1, \dots, x_n$ , 可迭代计算得出  $\varepsilon_1, \dots, \varepsilon_n$  的值:

$$\varepsilon_k = x_k + \beta_1 \varepsilon_{k-1} + \dots + \beta_q \varepsilon_{k-q}, \quad k=1, 2, \dots, n \quad (4.4)$$

而  $(\varepsilon_1, \dots, \varepsilon_n)$  可认为近似服从正态分布  $N(0, \sigma^2 I)$ , 因而  $x_1, \dots, x_n$  亦服从正态分布, 故

$(\varepsilon_1, \dots, \varepsilon_n)$  的近似概率密度为

$$L(\beta, \sigma^2) = f(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n; \beta, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{k=1}^n \varepsilon_k^2\right\}$$

对上式取对数, 即得

$$\ln L(\beta, \sigma^2) \approx -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{k=1}^n \varepsilon_k^2 \quad (3.4.5)$$

其中  $\varepsilon_k$  由假定及 (4.4) 式迭代而得, 即  $\varepsilon_k = x_k + \beta_1 \varepsilon_{k-1} + \dots + \beta_q \varepsilon_{k-q}$ , 易见, 它们不仅与  $x_1, \dots, x_n$  有关, 亦与参数  $\beta$  有关, 为确定参数  $\beta$  与  $\sigma^2$ , 记  $\varepsilon_1, \dots, \varepsilon_n$  的平方和为

$$S(\beta) = \sum_{k=1}^n \varepsilon_k^2 = \sum_{k=1}^n (x_k + \beta_1 \varepsilon_{k-1} + \dots + \beta_q \varepsilon_{k-q})^2$$

现在, 再求估计值  $\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_q)$  使  $S(\beta)$  达到最小, 即

$$S(\hat{\beta}) = \min\{S(\beta)\}$$

即为 $\beta$ 的最小平方差估计，亦为 $\beta$ 的近似极大似然估计。

由似然方程  $\ln L(\beta, \sigma^2) \approx -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} S(\beta)$  可知， $S(\beta)$  满足方程：

$$\frac{\partial}{\partial \beta} [\ln L(\beta, \sigma^2)] = -\frac{1}{2\sigma^2} \frac{\partial}{\partial \beta} [S(\beta)] = 0$$

$$\frac{\partial}{\partial \sigma^2} [\ln L(\beta, \sigma^2)] = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} S(\beta) = 0$$

因而，估计  $S(\hat{\beta})$  应满足等式：

$$\frac{\partial}{\partial \beta} [S(\hat{\beta})] = 0, \quad \hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_n)$$

$S(\hat{\beta})$  确定以后， $\sigma^2$  的估计相应得出，即为

$$\hat{\sigma}^2 = \frac{S(\hat{\beta})}{n}$$

然而，这样的估计  $\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_n)$  依然难以求出，实际上仍采用数值计算方法

求  $S(\beta)$  的极小值。

#### 4. 自回归逼近拟合方法

由于上述方法在实际中难以采用，所以我们讨论一种实际中便于使用的方法。我们注意到，对于可逆的  $MA(q)$  模型而言，它也可视作一个  $AR(+\infty)$  模型，因而在实际中，可以利用适当高阶的  $AR$  模型来近似代替低阶的  $MA$  模型，这样的方法称为自回归逼近拟合方法。具体做法是：

第一步：利用原始数据  $x_1, \dots, x_n$  作自回归模型  $AR(p)$  的拟合，即：

(1) 用 AIC 准则确定阶数  $p$  值，或直接取较大的  $p$  值。一般地，当样本容量  $n$  不太大时，取  $p \approx n/10$ ，当样本容量  $n$  较大时，取  $p \gg q$ ；

(2) 在确定阶数  $p$  后，再利用尤尔—沃克方法估计  $AR(p)$  中参数

$\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_n$ ，使其满足：

$$x_t = \hat{\alpha}_1 x_{t-1} + \hat{\alpha}_2 x_{t-2} + \dots + \hat{\alpha}_p x_{t-p} + \hat{\varepsilon}_t$$

第二步：由上述估计的  $AR(p)$  模型递推计算残差列  $\{\hat{\varepsilon}_t\}$ ，即：

$$\hat{\varepsilon}_t = x_t - \hat{\alpha}_1 x_{t-1} - \hat{\alpha}_2 x_{t-2} - \cdots - \hat{\alpha}_p x_{t-p}, \quad t = p+1, p+2, \dots, n$$

第三步：再视残差列  $\{\hat{\varepsilon}_t\}$  为独立序列，利用线性回归模型：

$$x_t = \beta_1 \varepsilon_{t-1} + \beta_2 \varepsilon_{t-2} + \cdots + \beta_q \varepsilon_{t-q} + \varepsilon_t, \quad t = p+1, p+2, \dots, n$$

确定出参数  $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_n$ ，即令

$$x = \begin{bmatrix} x_{p+q+1} \\ x_{p+q+2} \\ \vdots \\ x_n \end{bmatrix}, \quad \hat{E} = \begin{bmatrix} \hat{\varepsilon}_{p+q} & \hat{\varepsilon}_{p+q-1} & \cdots & \hat{\varepsilon}_{p+1} \\ \hat{\varepsilon}_{p+q+1} & \hat{\varepsilon}_{p+q} & \cdots & \hat{\varepsilon}_{p+1} \\ \vdots & \vdots & \cdots & \vdots \\ \hat{\varepsilon}_{n-1} & \hat{\varepsilon}_{n-2} & \cdots & \hat{\varepsilon}_{n-q} \end{bmatrix}, \quad \hat{\varepsilon} = \begin{bmatrix} \varepsilon_{p+q+1} \\ \varepsilon_{p+q+2} \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

则上式成为线性模型  $x = \hat{E}\beta + \varepsilon$ ， $\hat{\varepsilon} \sim N(0, \sigma^2 I)$

于是可得  $\beta$  的最小二乘估计为

$$\hat{\beta} = (\hat{E}^T \hat{E})^{-1} \hat{E}^T x$$

上述方法所得的  $\beta$  的估计即为自回归逼近拟合估计。由于此估计不涉及非线性代数方程，所以有明显的表达式，适宜在实际中使用。

### 三、拟合模型的检验

$MA(q)$  模型的检验方法与  $AR(p)$  模型的检验方法一样，通常也采用检验  $\{\varepsilon_t\}$  是否独立序列的方法：如

(1) 首先由初值  $\varepsilon_0, \varepsilon_{-1}, \dots, \varepsilon_{-\hat{q}+1}$  与  $MA(q)$  模型

$$x_t = \varepsilon_t - \beta_1 \varepsilon_{t-1} - \beta_2 \varepsilon_{t-2} - \cdots - \beta_q \varepsilon_{t-q}, \quad t = 1, 2, \dots, n$$

计算  $\hat{\varepsilon}_1, \hat{\varepsilon}_2, \dots, \hat{\varepsilon}_n$ ，其中  $\hat{q}$  为  $q$  估计值；

(2) 检验  $\hat{\varepsilon}_1, \hat{\varepsilon}_2, \dots, \hat{\varepsilon}_n$  是否独立序列，若是，则  $MA(q)$  模型为真，否则不是  $MA(q)$  模型。

也可采用拟合优度检验方法与峰度偏度检验方法作  $\{\varepsilon_t\}$  的正态性检验。