

§ 3.5 自回归滑动平均模型的拟合

设时间序列 $\{x_t\}$ 满足 $ARMA(p, q)$ 模型:

$$x_t = \sum_{i=1}^p \alpha_i x_{t-i} + \varepsilon_t - \sum_{j=1}^q \beta_j \varepsilon_{t-j}, \quad t = p+1, p+2, \dots, n$$

其中 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_p)'$, $\beta = (\beta_1, \beta_2, \dots, \beta_q)'$ 为模型参数, 满足前述及平稳性及可逆性等条件, 而 $\{\varepsilon_t\}$ 为独立序列, 且

$$E\varepsilon_t = 0, E\varepsilon_t^2 = \sigma^2, E\varepsilon_t^4 < +\infty.$$

已知样本值 x_1, x_2, \dots, x_n , 求与之适应的 $ARMA(p, q)$ 模型的方法与前述方法类似。即首先求假设 $ARMA(p, q)$ 的参数的估计, 再确定模型的阶数, 最后作模型拟合假设检验, 以确定最终模型。

一、 $ARMA(p, q)$ 模型的阶数 p 与 q 的估计

如果时间序列 $\{x_t\}$ 为 $ARMA(p, q)$ 模型, 其中自回归阶数 p 与滑动平均阶数 q 均未知, 则利用样本值首先对其进行估计, 常用的估计方法有自相关函数与偏相关函数分析法, AIC 准则方法或 BIC 准则方法等。

1. 自相关函数与偏相关函数分析法

因为一个平稳可逆序列为 $ARMA(p, q)$ 模型的特征是, 其偏相关函数 α_{kk} 与自相关函数 ρ_k 均为拖尾的, 即若偏相关函数 α_{kk} 在 p 以后截尾, 则应拟和 $AR(p)$ 模型; 若其自相关函数 ρ_k 在 q 以后截尾, 则应拟合 $MA(q)$ 模型; 所以当偏相关函数 α_{kk} 与自相关函数 ρ_k 均是拖尾时, 应当考虑可以拟和 $ARMA(p, q)$ 模型。但是这一方法只能说明是否可以拟和 $ARMA(p, q)$ 模

型，不能说明具体的阶数 p 和 q 当取何值。因此具体确定阶数 p 和 q 的估计还需借助别的方法。此分析法的步骤为：

(1) 首先将原数据零均值化：即由样本值 x_1, x_2, \dots, x_n ，计算均值

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \text{ 再令 } y_t = x_t - \bar{x}, t = 1, 2, \dots, n, \text{ 则 } \{y_t\} \text{ 为零均值序列}$$

(2) 计算样本自协方差函数

$$\hat{\gamma}_k = \frac{1}{n} \sum_{j=1}^{n-k} (x_j - \bar{x})(x_{k+j} - \bar{x}) = \frac{1}{n} \sum_{j=1}^{n-k} y_j y_{k+j} \quad k = 0, 1, 2, \dots$$

(3) 计算样本自相关函数：即

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}$$

(4) 再用迭代法计算样本偏相关函数 α_{kk} ：

$$\hat{\alpha}_{1,1} = \hat{\rho}_1$$

$$\hat{\alpha}_{k+1,k+1} = (\hat{\rho}_{k+1} - \sum_{j=1}^k \hat{\rho}_{k+1-j} \hat{\alpha}_{jk})(1 - \sum_{j=1}^k \hat{\rho}_j \hat{\alpha}_{jk})^{-1}$$

其中 $\hat{\alpha}_{j,k+1} = \hat{\alpha}_{jk} - \hat{\alpha}_{k+1,k+1} \hat{\alpha}_{k-j+1,k}, \quad j = 1, 2, \dots, k$

(5) 将 $(k, \hat{\rho}_k)$ 与 $(k, \hat{\alpha}_{kk})$ 分别描在笛卡尔坐标图上，观察，若从某个 k 以后， $\hat{\rho}_k$ 明显接近于零，则该 k 即为所求阶数 q 的估计 \hat{q} ，此时模型为 $MA(q)$ ；若 $\hat{\alpha}_{kk}$ 从某个 k 以后明显接近于零，则该 k 即为所求阶数 p 的估计 \hat{p} ，此时模型为 $AR(p)$ 。若 $\hat{\rho}_k$ 与 $\hat{\alpha}_{kk}$ 都没有明显的接近于零的趋势，则此时模型应为 $ARMA(p, q)$ 。

2. AIC 准则方法与 BIC 准则方法

可以将求 $AR(p)$ 模型阶数 p 的 AIC 准则方法与 BIC 准则方法加以推广, 即得求 $ARMA(p, q)$ 模型阶数 p 与 q 的 AIC 准则方法与 BIC 准则方法:

首先确定实数 P 为真阶数 p 与 q 的公共上界, 再引入了以下所谓的 AIC 准则函数:

$$AIC(k, j) = \ln \hat{\sigma}^2(k, j) + \frac{2(k+j)}{n}, \quad k, j = 0, 1, \dots, P$$

其中 $\hat{\sigma}^2(k, j)$ 为取阶数 $p = k, q = j$ ($0 \leq k, j \leq P$) 时 σ^2 的估计, 而 $p = 0$ 时, $\hat{\sigma}^2 = \hat{\gamma}_0$, 一般 P 的取值视实际情况由经验而定。再取 (\hat{p}, \hat{q}) , 使其满足下式:

$$AIC(\hat{p}, \hat{q}) = \min_{0 \leq k, j \leq P} AIC(k, j)$$

则此 \hat{p} 与 \hat{q} 即为所求 p 与 q 的 AIC 准则估计。

也可采用 AIC 准则修改形式, 即 BIC 准则函数

$$BIC(k) = \ln \hat{\sigma}^2(k, j) + \frac{(k+j) \ln n}{n}, \quad k, j = 0, 1, 2, \dots, P$$

确定 \hat{p} , 使其满足下式:

$$BIC(\hat{p}, \hat{q}) = \min_{1 \leq k, j \leq P} BIC(k, j)$$

由此得到的 \hat{p} 与 \hat{q} 为所求 p 与 q 的 BIC 准则估计。

因此利用 AIC 准则判断步骤是:

- (1) 首先凭经验选定阶数 p 与 q 的公共上界 P 值, 则 $0 \leq p, q \leq P$;
- (2) 再由样本值 x_t, \dots, x_n 迭代求出 σ^2 的最小二乘估计或尤尔—沃克估计

$$\begin{aligned} \hat{\sigma}^2(k, j) &= \hat{\gamma}_0 - \hat{\alpha}'(k, j) \hat{b}_k \\ &= \hat{\gamma}_0 - b_k' \Gamma^{-1}(k, j) b_k \quad k, j = 0, 1, 2, \dots, P \\ k=0, \quad \hat{\sigma}^2 &= \hat{\gamma}_0 \end{aligned}$$

(3) 将 $\hat{\sigma}^2(k, j)$ 代入 $A(k, j) = \text{AIC}(k, j) = \ln \hat{\sigma}^2(k, j) + \frac{2(k+j)}{n}$ 得 $A(0,0), A(0,1), A(1,1), \dots, A(P, P)$, 若有 $A(\hat{p}, \hat{q}) = \min_{0 \leq k, j \leq P} A(k, j)$, 则 \hat{p} 与 \hat{q} 为所求的 AIC 准则估计。

二、ARMA(p, q) 模型的参数估计

若时间序列 $\{x_t\}$ 为 $\text{ARMA}(p, q)$, 则模型参数包括 $\alpha_1, \alpha_2, \dots, \alpha_p, \beta_1, \beta_2, \dots, \beta_q$ 及 σ^2 等 $p+q+1$ 个未知参数, 也用矩估计法, 极大似然估计法与自回归逼近方法进行估计。

1. 矩估计法

利用样本矩代替总体矩的方法, 求未知参数的方法称为矩估计法。其作法步骤为:

(1) 首先由 x_1, \dots, x_n 计算自协方差函数 $\hat{\gamma}_k$;

(2) 由数字矩阵等式 $\hat{\Gamma}_{pq} \hat{\alpha} = \hat{b}$

求得自回归系数 $\alpha = (\alpha_1 \cdots \alpha_p)'$ 的矩估计: $\hat{\alpha} = \hat{\Gamma}_{pq}^{-1} \hat{b}$

$$\text{其中 } \hat{\Gamma}_{pq} = \begin{pmatrix} \hat{\gamma}_q & \hat{\gamma}_{q-1} & \cdots & \hat{\gamma}_{q-p+1} \\ \hat{\gamma}_{q+1} & \hat{\gamma}_q & \cdots & \hat{\gamma}_{q-p+2} \\ \cdots & \cdots & \cdots & \cdots \\ \hat{\gamma}_{q+p-1} & \hat{\gamma}_{q+p-2} & \cdots & \hat{\gamma}_q \end{pmatrix}, \quad \hat{b} = \begin{pmatrix} \hat{\gamma}_{q+1} \\ \hat{\gamma}_{q+2} \\ \vdots \\ \hat{\gamma}_{q+p} \end{pmatrix}$$

求出 $\hat{\alpha}$ 的估计。

(3) 再将上述自回归系数 $\alpha = (\alpha_1 \cdots \alpha_p)'$ 的矩估计代回模型中, 即得:

$$y_t \triangleq x_t - \sum_{i=1}^p \hat{\alpha}_i x_{t-i} = \varepsilon_t - \sum_{j=1}^q \beta_j \varepsilon_{t-j} \quad t = p+1, p+2, \dots, n$$

再求得模型 $\{y_t\}$ 的自相关函数的估计 $\hat{\gamma}_k(y)$, $k = 1, 2, \dots, q$

$$\hat{\gamma}_k(y) = \sum_{i=0}^p \sum_{j=0}^p \hat{\alpha}_i \hat{\alpha}_j \gamma_{i-j+k} = \begin{cases} \hat{\sigma}^2 (1 + \sum_{j=1}^q \beta_j^2) & k=0 \\ \hat{\sigma}^2 (-\hat{\beta}_k + \sum_{j=1}^{q-k} p_j \beta_{j+k}) & k=1, 2, \dots, q \end{cases}$$

从中即可求出 $\hat{\beta}$, $\hat{\sigma}^2$ 的估计。

2. 极大似然估计法

若对模型再附加条件 ε_t 服从正态分布 $N(0, \sigma^2)$, 则可采用近似极大似然估计法估计模型参数。

为方便近似计算, 再设初值 $x_0 = x_{-1} = \dots = x_{-q-p} = 0$,

$\varepsilon_0 = \varepsilon_{-1} = \dots = \varepsilon_{-q-p} = 0$, 则极大似然估计法作法步骤为:

(1) 首先通过初值与已知样本值迭代算出残差:

$$\begin{aligned} \varepsilon_k = & \beta_1 \varepsilon_{k-1} + \beta_2 \varepsilon_{k-2} + \dots + \beta_q \varepsilon_{k-q} + x_k - \\ & \alpha_1 x_{k-1} + \alpha_2 x_{k-2} + \dots + \alpha_p x_{k-p} \end{aligned}$$

$$\text{即} \quad \varepsilon_t = \sum_{i=1}^q \beta_i \varepsilon_{t-i} + x_t - \sum_{j=1}^p \alpha_j x_{t-j} \quad k=1, 2, \dots, n$$

(2) 建立似然函数

因为 $(\varepsilon_1, \dots, \varepsilon_n)$ 的分量相互独立, 且近似服从正态分布 $N(0, \sigma^2 I)$,

故其近似概率密度, 即似然函数为

$$L(\alpha, \beta, \sigma^2) = f(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n; \alpha, \beta, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{k=1}^n \varepsilon_k^2 \right\}$$

对上式取对数, 即得

$$\ln L(\beta, \sigma^2) \approx -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{k=1}^n \varepsilon_k^2 \quad (4.5)$$

其中 ε_k 由假定及(4.4)式迭代而得, 即 $\varepsilon_t = \sum_{i=1}^q \beta_i \varepsilon_{t-i} + x_t - \sum_{j=1}^p \alpha_j x_{t-j}$,

易见，它们不仅与 x_1, \dots, x_n 有关，亦与参数 α, β 有关。

(3) 确定 α, β 的极大似然估计

为确定参数 α, β 与 σ^2 的极大似然估计，记 $\varepsilon_1, \dots, \varepsilon_n$ 的平方和为构造残差平方和

$$S(\alpha, \beta) = \sum_{k=1}^n \varepsilon_k^2$$

由似然函数知，求出 $\hat{\alpha}, \hat{\beta}$ ，使满足 $L(\hat{\alpha}, \hat{\beta}) = \max L(\alpha, \beta)$ ，即使

$$S(\hat{\alpha}, \hat{\beta}) = \min S(\alpha, \beta)$$

由此求出的 $\hat{\alpha}, \hat{\beta}$ 为 α, β 的极大似然估计，亦即关于 S 的最小平方差估计

(近似)，于是 $\hat{\sigma}^2 = \frac{1}{n} S(\hat{\alpha}, \hat{\beta})$ 即为 σ^2 的极大似然估计。

注意：此法在实际中一般为数值解法。

3. 自回归逼近方法

$ARMA(p, q)$ 模型参数的自回归逼近方法与 $MA(q)$ 模型的自回归逼近方法类似，也是利用线性回归的思想，来作出 $\alpha_1, \alpha_2, \dots, \alpha_p, \beta_1, \beta_2, \dots, \beta_q$ 及 σ^2 等 $p+q+1$ 个未知模型参数估计，

这种估计虽然避免了求解非线性问题，但其估计只能是近似的。利用自回归逼近方法求模型参数估计的步骤为

第一步：首先利用原始数据 x_1, \dots, x_n 作高阶自回归滑动模型 $AR(p)$ 的拟合，即：

(1) 用 AIC 准则确定阶数 P 值，或直接取较大的 P 值。一般地，由于原时间序列为 $ARMA(p, q)$ 时，只有用较高阶的 $AR(P)$ 模型，取 $P \gg p, q$ ，才能较好的拟合原始数据序列；

(2) 在确定阶数 P 后，再利用尤尔—沃克方法估计 $AR(p)$ 中参数

$\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_n$ ，使其满足：

$$x_t = \hat{\alpha}_1 x_{t-1} + \hat{\alpha}_2 x_{t-2} + \dots + \hat{\alpha}_p x_{t-p} + \hat{\varepsilon}_t$$

第二步：由上述估计的 $AR(p)$ 模型递推计算残差列 $\{\hat{\varepsilon}_t\}$ ，即：

$$\hat{\varepsilon}_t = x_t - \hat{\alpha}_1 x_{t-1} - \hat{\alpha}_2 x_{t-2} - \dots - \hat{\alpha}_p x_{t-p}, \quad t = P+1, P+2, \dots, n$$

第三步：再视残差列 $\{\hat{\varepsilon}_t\}$ 为独立序列，利用线性回归模型：

$$x_t = \sum_{i=1}^p \alpha_i x_{t-i} + \hat{\varepsilon}_t - \sum_{j=1}^q \beta_j \hat{\varepsilon}_{t-j} \quad t = P+1, P+2, \dots, n$$

此为自回归与回归的混合模型，其矩阵形式为：

$$x = (X\hat{E}) \begin{pmatrix} \alpha \\ \beta \end{pmatrix} + \hat{\varepsilon} \quad \hat{\varepsilon} \sim N(0, \sigma^2 I)$$

$$\text{其中 } X = \begin{bmatrix} x_{P+q} & x_{P+q-1} & \dots & x_{P+q-p+1} \\ x_{P+q+1} & x_{P+q} & \dots & x_{P+q-p+2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n-1} & x_{n-2} & \dots & x_{n-p} \end{bmatrix}, \quad \hat{E} = \begin{bmatrix} \hat{\varepsilon}_{P+q} & \hat{\varepsilon}_{P+q-1} & \dots & \hat{\varepsilon}_{P+1} \\ \hat{\varepsilon}_{P+q+1} & \hat{\varepsilon}_{P+q} & \dots & \hat{\varepsilon}_{P+1} \\ \vdots & \vdots & \dots & \vdots \\ \hat{\varepsilon}_{n-1} & \hat{\varepsilon}_{n-2} & \dots & \hat{\varepsilon}_{n-q} \end{bmatrix},$$

$$\hat{\varepsilon} = (\varepsilon_{P+q+1} \quad \varepsilon_{P+q+2} \quad \dots \quad \varepsilon_n)' \quad \alpha = (\alpha_1, \alpha_2, \dots, \alpha_p)',$$

$\beta = (\beta_1, \beta_2, \dots, \beta_q)'$ ，于是可得 α 与 β 的最小二乘估计为

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} = \left[\begin{pmatrix} X' \\ \hat{E}' \end{pmatrix} \begin{pmatrix} X & \hat{E} \end{pmatrix} \right]^{-1} \begin{pmatrix} X' \\ \hat{E}' \end{pmatrix} x = \begin{pmatrix} XX' & X\hat{E}' \\ \hat{E}'X & \hat{E}'\hat{E} \end{pmatrix}^{-1} \begin{pmatrix} X'x \\ \hat{E}'x \end{pmatrix}$$

上述方法所得的 $\alpha_1, \alpha_2, \dots, \alpha_p, \beta_1, \beta_2, \dots, \beta_q$ 的估计即为

$ARMA(p, q)$ 的自回归逼近拟合估计。

三、 $ARMA(p, q)$ 模型的拟合检验

检验 $ARMA(p, q)$ 模型与检验 $AR(p)$ 模型 $MA(q)$ 模型的方法基本相

同，都是检验其拟合残差序列是否为独立序列，不同的是，各自获得拟合残差序列时使用各自不同的拟合模型而已。即实际上，检验 $\{x_t\}$ 是否为 $ARMA(p, q)$ 时，只需检验残差列 $\{\varepsilon_t\}$ 是否独立序列即可，而残差列的估计值 $\{\hat{\varepsilon}_t\}$ 可由样本值 x_1, \dots, x_n 计算得出，最后再利用判别独立序列的方法，判断 $\{\hat{\varepsilon}_t\}$ 是否独立序列，若是，则认为 $\{x_t\}$ 为 $ARMA(p, q)$ 序列，否则认为 $\{x_t\}$ 不是 $ARMA(p, q)$ 序列。

因此检验 $ARMA(p, q)$ 模型的具体步骤为：

i) 提出假设 $H_0: x_t = \sum_{i=1}^p \alpha_i x_{t-i} + \varepsilon_t - \sum_{k=1}^q \beta_k \varepsilon_{t-k}, \quad t = p+1, \dots, n$

ii) 将参数的估计值 $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_p, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_q$ 与阶数的估计 \hat{p} 与 \hat{q} 代替 H_0 中的 $\alpha_1, \alpha_2, \dots, \alpha_p, \beta_1, \beta_2, \dots, \beta_q, \sigma^2, p$ 与 q ，故实际检验

$$H_0: x_t = \sum_{i=1}^{\hat{p}} \hat{\alpha}_i x_{t-i} + \varepsilon_t - \sum_{k=1}^{\hat{q}} \hat{\beta}_k \varepsilon_{t-k}, \quad t = p+1, \dots, n$$

iii) 由上式计算残差：

$$\varepsilon_t = \sum_{i=1}^{\hat{q}} \hat{\beta}_i \varepsilon_{t-i} + x_t - \sum_{k=1}^{\hat{p}} \hat{\alpha}_k x_{t-k}, \quad t = \hat{p}+1, \hat{p}+2, \dots$$

iv) 由 $\{\hat{\varepsilon}_t\}$ 求自协方差函数

$$\hat{\gamma}_k(\varepsilon) = \frac{1}{n-p} \sum_{t=1}^{n-p-k} \varepsilon_{t+p} \varepsilon_{t+p+k} \quad k = 0, 1, 2, \dots$$

$$\hat{\rho}_k(\varepsilon) = \hat{\gamma}_k / \hat{\gamma}_0(\varepsilon)$$

v) 若 $\{\hat{\rho}_k(\varepsilon), k = 0, 1, 2, \dots, n\}$ 中约有 68.3% 的点落在纵坐标

$\hat{\rho} = \pm 1/n$ 内，约有 95.4% 的点落在纵坐标 $\hat{\rho} = \pm 2/n$ 内，则

$(\varepsilon_{p+1}, \varepsilon_{p+2}, \dots, \varepsilon_n)$ 为独立序列样本值，此时接受 H_0 ，否则拒绝 H_0 。